Matematički fakultet

Predmet: Istraživanje podataka 2

Klasifikacija ponašanja rojeva (Swarm Behavior)

Student: Danilo Nikolaš

5. mart 2026.

Sadržaj

1 Uvod i definisanje problema **2**

2 Analiza skupa podataka i preprocesiranje **2**
2.1 Podela podataka i standardizacija 3

3 Redukcija dimenzionalnosti (PCA) **3**
3.1 Analiza varijanse 3
3.2 Vizuelizacija u redukovanom prostoru 4

4 Evaluacija i Stres testiranje modela **5**
4.1 Performanse na celokupnom skupu (2400 atributa) 5
4.2 Vremenska kompleksnost i opravdanost PCA kompresije 6
4.3 Metodologija Stres Testa 7

5 Detaljna evaluacija: ROC krive i matrice konfuzije **8**
5.1 ROC krive pri ekstremnoj kompresiji 8
5.2 Matrica konfuzije i validacija strategije bez SMOTE algoritma 9

6 Zaključak **10**

Apstrakt

Ovaj seminarski rad bavi se problemom klasifikacije ponašanja rojeva (eng. *Swarm Behavior*) koristeći tehnike mašinskog učenja. Cilj je predvideti specifična ponašanja (kao što su *flocking*, *aligned* i *grouped*) na osnovu sirovih prostornih koordinata i vektora brzina iz *Boids* simulacija. Zbog ekstremne dimenzionalnosti skupa podataka koji sadrži 2400 atributa za svako opažanje, poseban fokus stavljen je na tehnike redukcije dimenzionalnosti (PCA) i stres-testiranje robusnosti različitih algoritama. Upoređene su performanse pet različitih modela, pri čemu su ansambl metode pokazale vrhunsku sposobnost generalizacije u visokodimenzionalnim prostorima.

1 Uvod i definisanje problema

Analiza i modelovanje ponašanja rojeva predstavlja jedan od klasičnih problema u domenu veštačke inteligencije i analize kompleksnih sistema. Modeli poput *Boids* algoritma (razvijenog od strane Craiga Reynoldsa) demonstriraju kako se kompleksno globalno ponašanje cele grupe jedinki može postići pomoću jednostavnih lokalnih pravila: separacije, poravnanja (eng. *alignment*) i kohezije (eng. *cohesion*).

U ovom projektu, zadatak je rešavanje problema binarne klasifikacije nad podacima generisanim iz ovakvih simulacija. Svaki instancirani red u skupu podataka predstavlja jedan "snimak" (eng. *snapshot*) roja u vremenu i sadrži 2400 atributa. Ovi atributi direktno opisuju x i y koordinate, kao i x i y komponente vektora brzine za ukupno 200 nezavisnih jedinki (boida) u roju.

Glavni izazovi koje ovaj rad rešava su:

- **Ekstremna dimenzionalnost prostora:** Rad sa 2400 ulaznih kolona zahteva pažljivo preprocesiranje i redukciju kako bi se izbeglo preprilagođavanje (eng. *overfitting*) i prevelika računarska kompleksnost ("kletva dimenzionalnosti").
- **Prepoznavanje obrazaca ponašanja:** Algoritmi mašinskog učenja moraju pronaći skrivene matematičke obrasce koji odgovaraju gorenavedenim pravilima roja.
- **Evaluacija pod ekstremnom kompresijom:** Merenje degradacije performansi modela kada se skup podataka kompresuje na drastično manji broj dimenzija pomoću Analize glavnih komponenti (PCA).

U narednim poglavljima biće detaljno opisan proces čišćenja podataka, metodologija skaliranja i redukcije, kao i uporedna analiza algoritama: Logistička regresija, K-najbližih suseda (KNN), Mašine potpornih vektora (SVM), Slučajne šume (Random Forest) i LightGBM.

2 Analiza skupa podataka i preprocesiranje

Podaci korišćeni u ovom radu podeljeni su u tri odvojena skupa, od kojih svaki predstavlja specifičan obrazac ponašanja:

- **flocking.csv** - Razdvaja stanje gde su jedinke raspršene (Klasa 0) od stanja gde formiraju roj (Klasa 1).
- **aligned.csv** - Razdvaja neusklađeno kretanje (Klasa 0) od poravnatog kretanja u istom pravcu (Klasa 1).
- **grouped.csv** - Razdvaja odvojene jedinke (Klasa 0) od jedinki koje su zbijene na gomili (Klasa 1).

Svaki red u ovim datotekama sadrži x i y koordinate, kao i odgovarajuće komponente vektora brzine za 200 nezavisnih jedinki, što rezultuje sa ukupno 2400 prediktivnih atributa. Ciljna promenljiva je binarna (*Class*).

2.1 Podela podataka i standardizacija

Da bi se osigurala objektivna evaluacija i sprečilo "curenje podataka" (eng. *Data Leakage*), primenjena je stroga podela skupa podataka. Za obuku modela izdvojeno je 80% podataka, dok je preostalih 20% ostavljeno za testiranje, uz očuvanje stratifikacije klasa kako bi se poštovao početni balans. Skaliranje je izvršeno pomoću *StandardScaler* metode. Standardizacija je "naučena" isključivo na trening skupu, nakon čega je ista transformacija primenjena na test skup.

3 Redukcija dimenzionalnosti (PCA)

Zbog ekstremno visoke dimenzionalnosti (2400 atributa), prisutan je rizik od "kletve dimenzionalnosti", kao i visoka verovatnoća multikolinearnosti između vektora brzine susednih jedinki. Kako bi se ovi problemi prevazišli, primenjena je Analiza glavnih komponenti (eng. *Principal Component Analysis - PCA*).

3.1 Analiza varijanse

S obzirom na to da je PCA nenadgledan algoritam koji operiše isključivo nad ulaznom matricom prostornih karakteristika (X), a sva tri skupa podataka dele identičnu ulaznu strukturu Boids simulacije (razlikuju se samo po ciljnoj promenljivoj y), proces kompresije informacija je univerzalan za celokupan sistem.

Algoritam je prvobitno testiran kako bi se uvidelo koliko je komponenti potrebno zadržati da bi se objasnilo 90% varijanse originalnog skupa podataka. Analiza je pokazala da se iz početnih 2400 atributa željeni prag informacija (90%) postiže zadržavanjem oko **455 glavnih komponenti**.

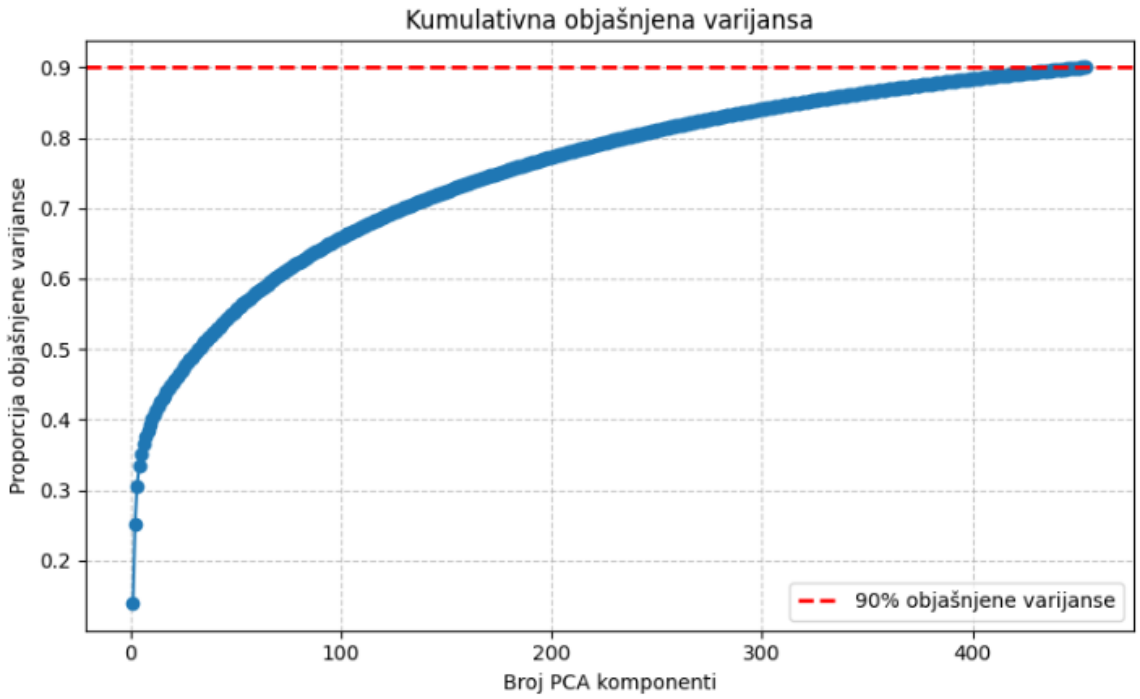

Slika 1: Kumulativna objašnjena varijansa

Ovim postupkom, originalni prostor kompresovan je na znatno manji broj međusobno ortogonalnih (nezavisnih) komponenti. Ova redukcija ne samo da je drastično ubrzala vreme treniranja modela, već je i umanjila uticaj šuma u podacima.

3.2 Vizuelizacija u redukovanom prostoru

Kako bi se ispitala linearna i nelinearna razdvojivost klasa, primenjena je vizuelizacija celokupnih rojeva u dvodimenzionalnom (2D) prostoru glavnih komponenti.

Važno je naglasiti način na koji se ovaj grafik (Slika 2) interpretira. Svaka pojedinačna tačka na grafiku ne predstavlja jednu pticu, već predstavlja čitav jedan roj (ponašanje svih 200 jedinki u jednom specifičnom vremenskom trenutku), odnosno jedan celokupan red iz originalnog skupa podataka, kompresovan u svega dve koordinate. Boje tačaka označavaju stvarnu klasu kojoj taj roj pripada (npr. formiran roj naspram raspršenog).

Ukoliko se tačke iste boje na ovom grafiku grupišu u jasno odvojene klastere (oblake), to je direktan vizuelni dokaz da su obrasci ponašanja matematički razdvojivi. Uvidom u generisane grafike, primećuje se da se klase relativno dobro razdvajaju u prostoru glavnih komponenti, što potvrđuje da algoritmi mašinskog učenja imaju snažnu informacionu osnovu za uspešnu klasifikaciju, uprkos ekstremnoj redukciji sa 2400 na samo 2 dimenzije.

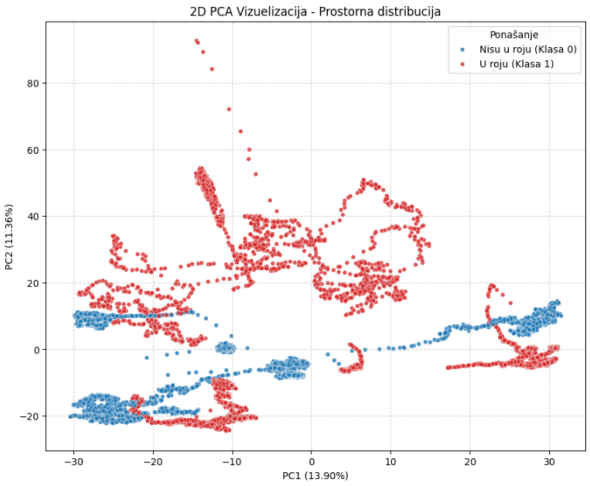

a) Flocking

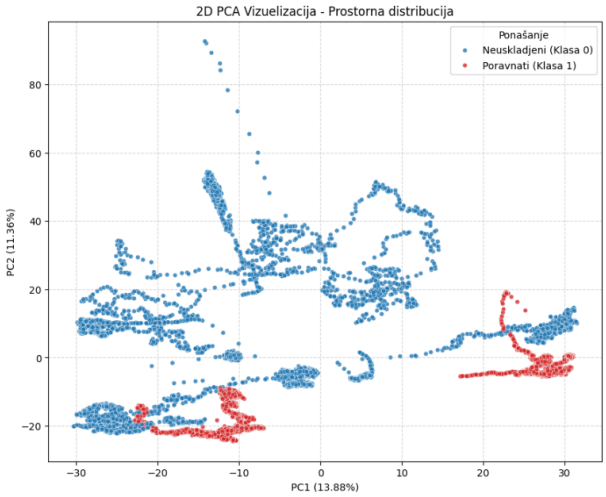

b) Aligned

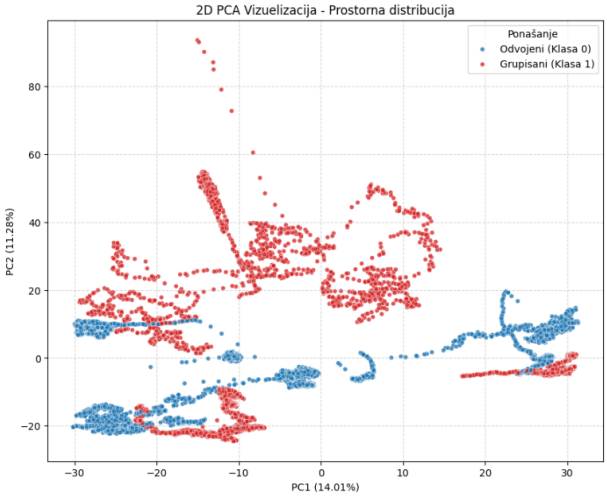

c) Grouped

Slika 2: Vizuelni prikaz distribucije klasa u prostoru

4 Evaluacija i Stres testiranje modela

Nakon osnovnog procesiranja, pristupilo se uporednoj analizi pet algoritama: *Logistička regresija*, *K-Nearest Neighbors (KNN)*, *Support Vector Machine (SVM)*, *Random Forest* i *LightGBM*.

4.1 Performanse na celokupnom skupu (2400 atributa)

Testiranje je sprovedeno nezavisno na sva tri skupa podataka: *flocking.csv* (prepoznavanje opšteg formiranja roja), *aligned.csv* (prepoznavanje usklađenosti pravca) i *grouped.csv* (prepoznavanje fizičke zbijenosti).

Kada su modeli trenirani na celokupnom prostoru od 2400 kolona, snažni nelinearni i ansambl algoritmi ostvarili su savršenu ili gotovo savršenu tačnost na sva tri obrasca ponašanja, što je dovelo u pitanje preprilagodjenost modela. Inicijalna sumnja u ovakve rezultate je odbačena, jer je zaključeno da je takvo ponašanje logično, s obzirom na to da su podaci generisani iz determinističke kompjuterske simulacije (Boids), pa su kompleksni algoritmi lako prepoznali i usvojili ta pravila. S obzirom na to da su vrednosti svih posmatranih metrika (Accuracy, Preci-

sion, Recall, F1-Score) dostigle gotovo maksimalne vrednosti za sva tri skupa podataka, njihovi grafički prikazi su vizuelno identični. Zbog toga je na Slici 3 prikazan samo jedan reprezentativan grafik koji jasno oslikava performanse svih 5 modela na celokupnom skupu atributa.

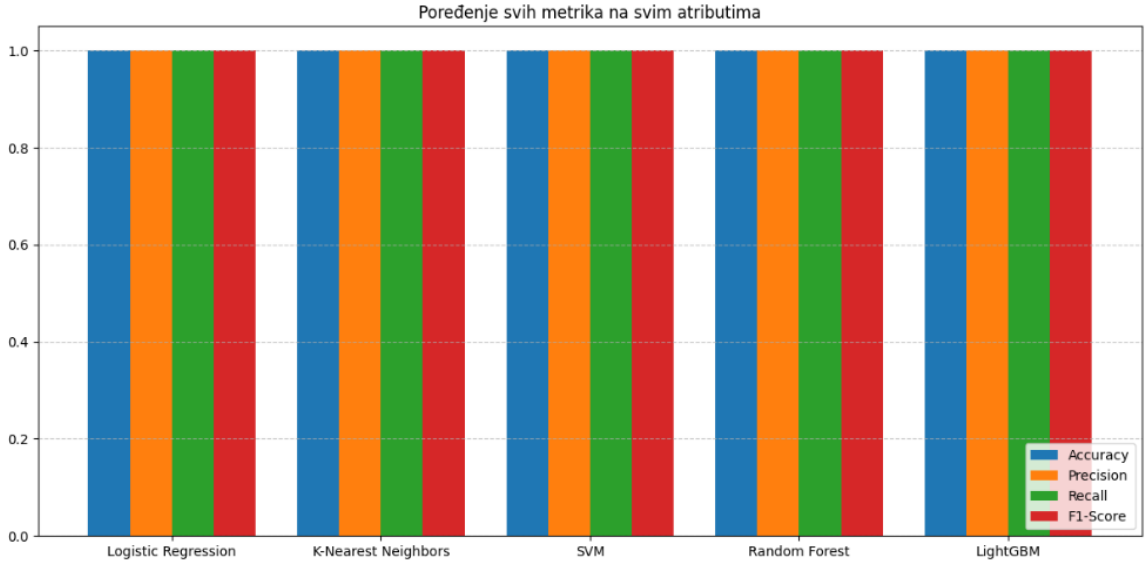

Slika 3: Poredjenje metrika na svim atributima

4.2 Vremenska kompleksnost i opravdanost PCA kompresije

Iako su modeli pokazali visoke performanse predvidjanja, merenje vremena treniranja i predikcije na punom skupu od 2400 atributa naspram PCA kompresovanog skupa otkrilo je suštinske razlike u arhitekturi samih algoritama. Uticaj redukcije na vreme izvršavanja detaljno je vizuelizovan na Slici 4.

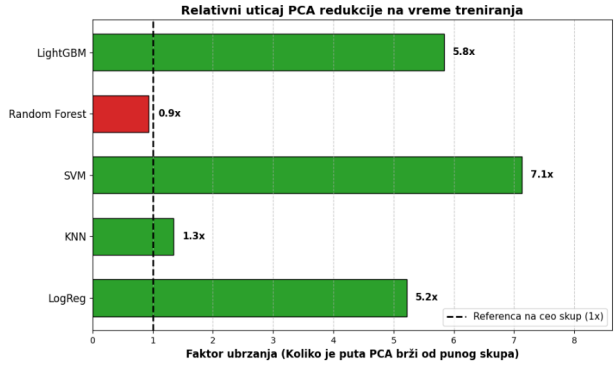

a) Flocking

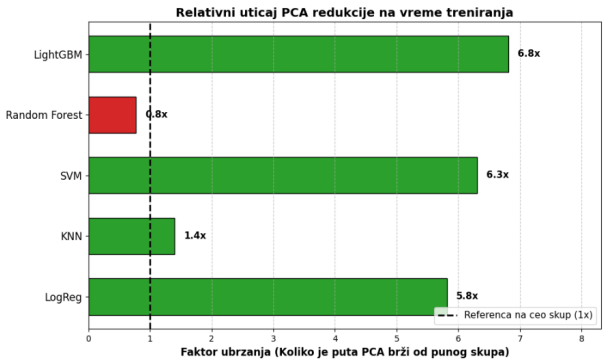

b) Aligned

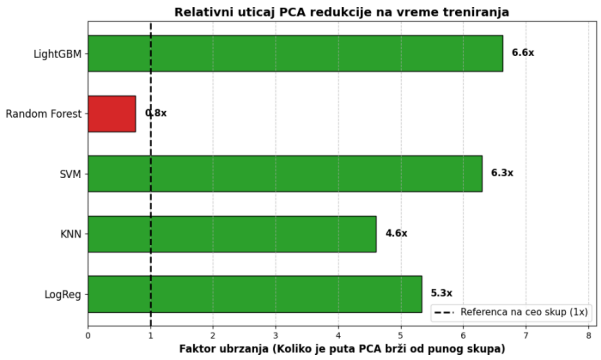

c) Grouped

Slika 4: Faktor ubrzanja algoritama nakon primene PCA redukcije

Iako apsolutno vreme treniranja jednostavnijih algoritama (poput Logističke regresije i KNN-a) iznosi svega par sekundi na punom skupu, te se na prvi pogled ne stiče utisak da im je optimizacija neophodna, grafici faktora ubrzanja nedvosmisleno dokazuju da primena PCA kompresije donosi drastično relativno ubrzanje – često ih čineći od 4 do čak 7 puta bržim, u zavisnosti od skupa podataka. Sa druge strane, algoritam zasnovan na kompleksnim kernel funkcijama, *Support Vector Machine (SVM)*, pokazao se kao apsolutno usko grlo sistema na punom skupu, zahtevajući nesrazmerno veliko vreme izvršavanja. Za ovaj model, kompresija je bila od esencijalnog značaja, jer mu je donela višestruko ubrzanje bez primetnog narušavanja preciznosti.

Jedini izuzetak u ovom procesu optimizacije jeste algoritam *Random Forest*, kome je redukcija dimenzionalnosti na svim skupovima zapravo usporila vreme izvršavanja. Ovaj fenomen se objašnjava samom prirodom stabala odlučivanja. Originalni podaci iz simulacije sadrže mnogo nula i jasne ose kretanja koje *Random Forest* veoma brzo i efikasno razdvaja. Nasuprot tome, PCA rotira dimenzionalni prostor i transformiše te podatke u guste (eng. *dense*) matrice ispunjene decimalnim vrednostima, što algoritmu otežava pronalaženje optimalnih granica grananja. Ova opservacija jasno potvrđuje da PCA redukcija nije univerzalno rešenje za ubrzanje apsolutno svih algoritama, već njen uspeh zavisi od matematičke pozadine samog modela.

4.3 Metodologija Stres Testa

Kako bi se dokazala stvarna razlika u snazi algoritama i odbacila sumnja u trivijalnost problema, sproveden je tzv. ”Stres test”. Dimenzionalnost podataka je drastično oborena testiranjem na fiksnom, ekstremno malom broju glavnih komponenti.

Ovim postupkom podaci su dovedeni do nivoa informacione degradacije na kojoj se linearni modeli, poput Logističke regresije, u potpunosti ”raspadaju”, dok sofisticiraniji algoritmi poput LightGBM i dalje zadržavaju visoku moć generalizacije. Na Slici 5 vizuelno je prikazan uticaj

kompresije na performanse modela. Zbog razlike u distribuciji klasa, za *flocking* skup prikazan je uticaj na opštu tačnost (Accuracy), dok je za umereno nebalansirane skupove (*aligned* i *grouped*) prikazan uticaj na F1-meru, koja je otpornija na takve anomalije.

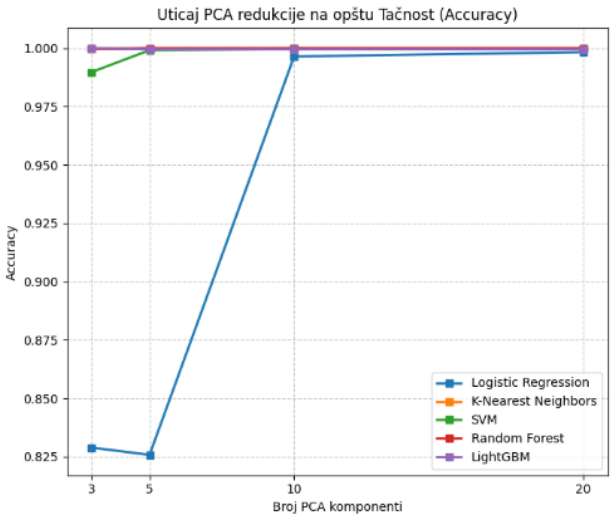

a) Flocking (Accuracy)

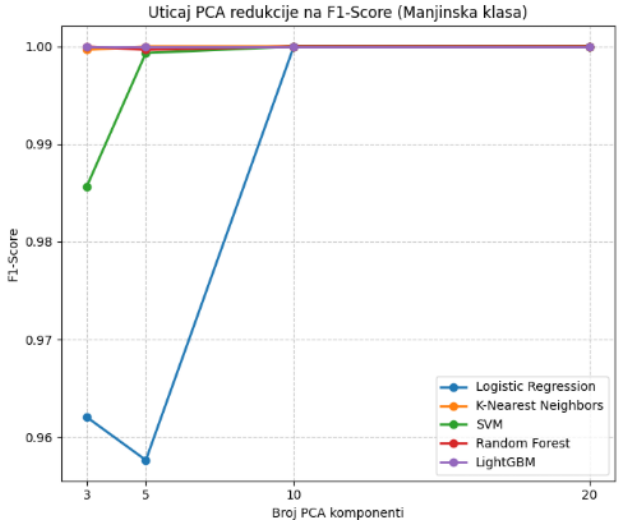

b) Aligned (F1-Score)

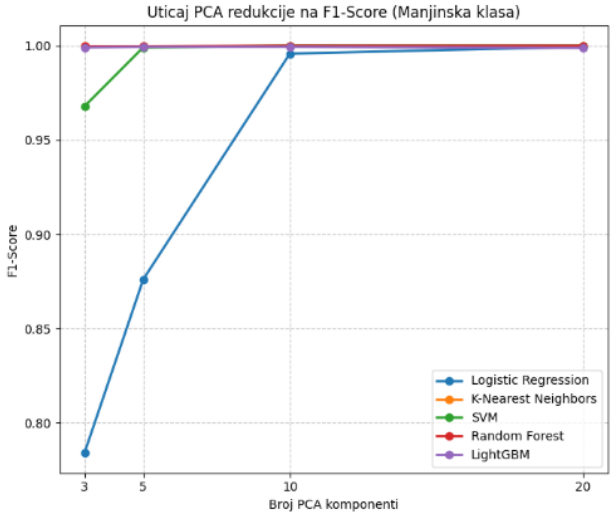

c) Grouped (F1-Score)

Slika 5: Rezultati PCA stres testa

5 Detaljna evaluacija: ROC krive i matrice konfuzije

5.1 ROC krive pri ekstremnoj kompresiji

ROC (eng. *Receiver Operating Characteristic*) krive i površina ispod njih (AUC - eng. *Area Under the Curve*) korišćene su kao ključna metrika za vizuelnu i kvantitativnu evaluaciju modela u uslovima ekstremnog gubitka informacija. Dok obična tačnost (Accuracy) može dati lažan osećaj sigurnosti, ROC kriva jasno prikazuje odnos između stope stvarno pozitivnih (TPR) i lažno pozitivnih (FPR) predikcija na različitim pragovima odlučivanja.

Analizom grafika za modele obučene na drastično redukovanom PCA skupu (sa samo 3 komponente), vizuelno je potvrđeno da ansambl modeli (poput *LightGBM* i *Random Forest*) zadržavaju

površinu ispod krive blizu idealne vrednosti od 1.0. Sa druge strane, kriva Logističke regresije primetno pada ka dijagonali (koja predstavlja nasumično pogađanje), čime se iznova dokazuje preosetljivost linearnih granica odlučivanja na nelinearne, visoko kompresovane prostorne podatke iz roja.

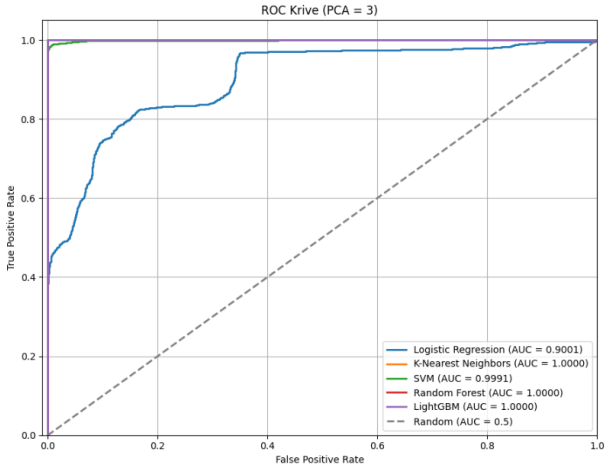

a) Flocking

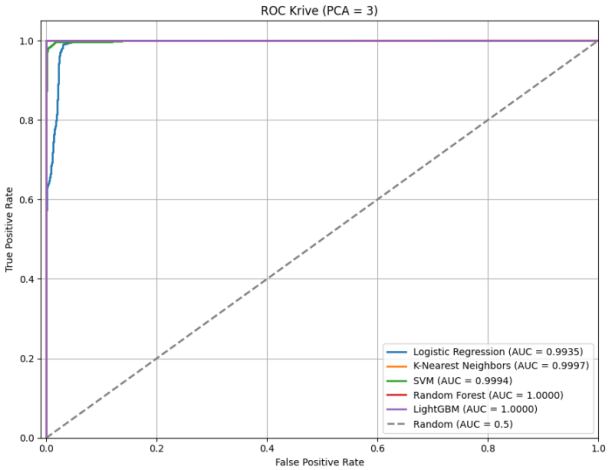

b) Aligned

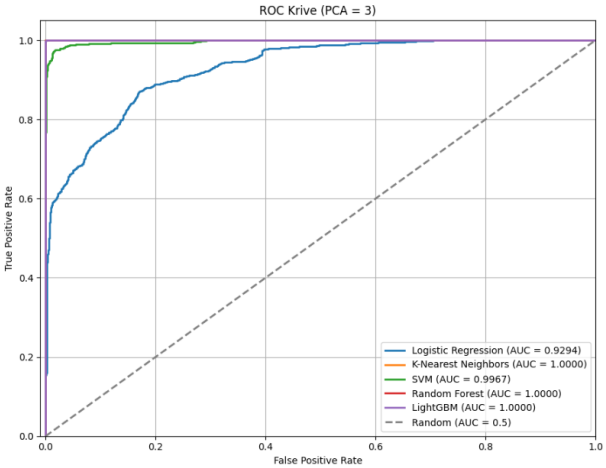

c) Grouped

Slika 6: Poređenje ROC krivih pet različitih modela

5.2 Matrica konfuzije i validacija strategije bez SMOTE algoritma

S obzirom na to da skupovi podataka *aligned.csv* i *grouped.csv* sadrže blagi disbalans klasa (na primer, odnos 69% prema 31% u korist jedne klase), bilo je neophodno grafički potvrditi da algoritmi ne favorizuju većinsku klasu. Zbog ove potencijalne opasnosti, u fazi preprocesiranja svesno je doneta odluka da se izbegne korišćenje SMOTE algoritma za veštačko balansiranje podataka, kako se ne bi narušio fizički integritet i realističnost *Boids* simulacije iz koje su vektori kretanja izvučeni.

Da bi se empirijski dokazala ispravnost ove odluke, generisane su matrice konfuzije za model sa najboljim performansama (*LightGBM*). Rezultati iz matrica nedvosmisleno pokazuju izrazito visok broj tačno pozitivnih (TP) i tačno negativnih (TN) predikcija, uz gotovo nepostojeći broj lažno pozitivnih (FP) i lažno negativnih (FN) vrednosti. Ovim je potvrđeno da model zaista pronalazi kompleksne matematičke granice ponašanja roja i ne pribegava trivijalnom predviđanju

dominantne klase, čime je strategija zadržavanja originalnog disbalansa u potpunosti opravdana.

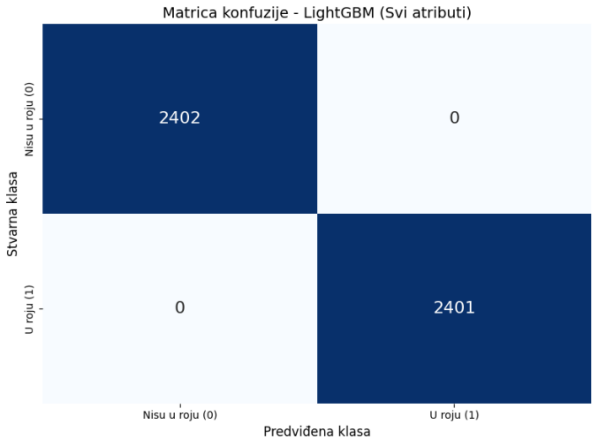

a) Flocking

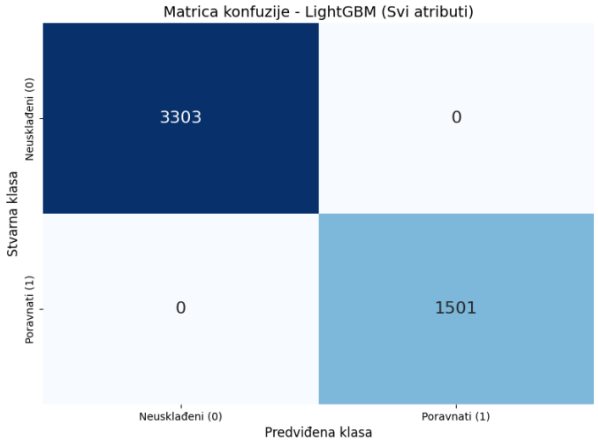

b) Aligned

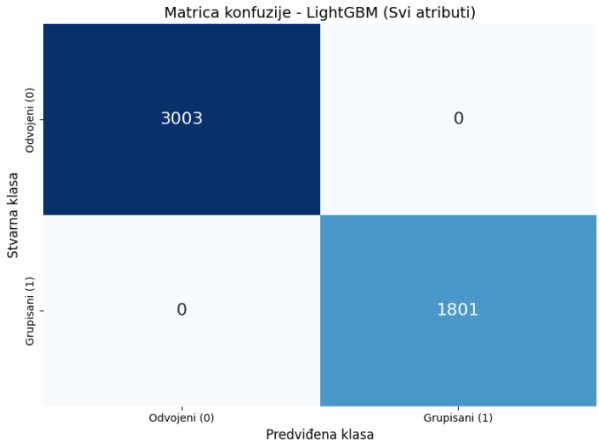

c) Grouped

Slika 7: Matrice konfuzije najboljeg modela (LightGBM)

Ovaj rezultat empirijski dokazuje ispravnost odluke da se odbaci korišćenje SMOTE algoritma, LightGBM uspeva da pronađe kompleksne granice odlučivanja bez potrebe za veštačkim generisanjem podataka, čime je u potpunosti očuvan fizički integritet skupa.

6 Zaključak

U okviru ovog seminarskog rada, uspešno je rešen problem binarne klasifikacije ponašanja rojeva analizom ekstremno dimenzionalnih podataka. Kroz seriju sprovedenih eksperimenata doneti su sledeći ključni zaključci:

- **Prepoznavanje obrazaca:** Modeli mašinskog učenja, a naročito ansambl metode, sposobni su da sa visokom preciznošću prepoznaju i usvoje matematička pravila *Boids* simulacije kada su im dostupni svi atributi. Analiza je takođe pokazala da se celokupno ponašanje jata dominantno manifestuje kao unija grupisanja i poravnanja.
- **Efikasnost i selektivni uticaj redukcije:** Primena Analize glavnih komponenti (PCA) efikasno kompresuje korelisana kretanja celog roja uz minimalan gubitak bitnih informacija

(prelazak sa 2400 na 455 atributa uz 90% varijanse). Ipak, ova redukcija ima različit uticaj na modele: dok je prostornim algoritmima poput SVM-a donela neophodno i drastično vremensko ubrzanje, algoritmi zasnovani na stablima (koji su već bili otporni na visoku dimenzionalnost) nisu osetili istu vrstu benefita zbog guste reprezentacije transformisanih podataka.

- **Robusnost algoritama:** "Stres test" je otkrio ključne razlike u arhitekturi modela pod uslovima ekstremne kompresije. Dok su linearni modeli preosetljivi na ekstremni gubitak prostornih informacija, sofisticirani ansambl algoritmi poput *LightGBM*-a i *Random Forest*-a zadržavaju klasifikacionu nadmoć i izuzetnu moć generalizacije. To ih čini idealnim izborom za modelovanje ovakvih kompleksnih fizičkih sistema, čak i u uslovima drastično smanjenih informacija.

Литература

[1] Reynolds, C. W. (1987). *Flocks, herds and schools: A distributed behavioral model*. ACM SIGGRAPH Computer Graphics, 21(4), 25-34.

[2] Kaggle. *Swarm Behavior Classification Dataset*. Dostupno na: `https://archive.ics.uci.edu/dataset/524/swarm+behaviour` (Pristupljeno: mart 2026).

[3] Vicsek, T., & Zafeiris, A. (2012). *Collective motion*. Physics Reports, 517(3-4), 71-140.